



南開大學
Nankai University

南 開 大 學

計 算 機 學 院

深度學習及應用實驗報告

實驗二 卷積神經網絡的實現

姓名：蘇航

學號：2111039

專業：信息安全

2024 年 5 月 29 日

摘要

本实验在理解基本卷积神经网络的基础上, 实现了 CNN 对 CIFAR10 数据集的识别. 同时我们也尝试了对基本神经网络的改进, 实现了 ResNet,DenseNet, 以及带 SE 结构的 RESNet, 实现了较高正确率的识别模型

关键字: 卷积神经网络;ResNet;DenseNet;SE 结构

目录

一、 实验要求	1
二、 实验内容	1
三、 实验过程	1
(一) 卷积神经网络的基本原理	1
(二) 原始 CNN 的实现	1
(三) 原始 CNN 的训练与评估	2
(四) ResNet 的实现	4
1. ResNet18 模型	4
2. 带 SE 结构的 ResNet	7
(五) DenseNet 的实现	9
四、 总结	11

一、 实验要求

本次实验要求掌握卷积神经网络 (CNN) 的基本原理并学会使用 PyTorch 搭建简单的 CNN 实现 CIFAR10 数据集分类, 同时掌握如何改进网络结构、调试参数以提升网络识别性能。

二、 实验内容

本实验要求根据原始版本卷积网络结构, 以及自己实现的 ResNet, DenseNet, 以及带 SE 结构的 ResNet 在 CIFAR10 数据集上的训练 LOSS 曲线以及准确率曲线

三、 实验过程

(一) 卷积神经网络的基本原理

卷积神经网络由卷积层, 激活函数, 池化层, 全连接层, 以及损失函数构成。其中卷积是其核心操作, 通过卷积操作, 提取输入数据的特征。卷积操作可以理解为在输入数据上滑动一个称为卷积核的小窗口, 然后对窗口中的数据进行加权求和, 得到输出特征图。具体的模型结构如下所示:




图 1: 卷积神经网络模型图

(二) 原始 CNN 的实现

实验要求我们实现简单的 CNN 网络结构, 如下所示. 对于这个 CNN 我们首先经过两次卷积操作, 后接最大池化层, 然后再接上 3 层全连接层. 具体来讲首先定义了一个卷积层, 输入通道数为 3, 输出通道数为 6, 卷积核大小为 5x5; 然后定义了一个最大池化层, 池化窗口大小为 2x2; 定义了另一个卷积层, 输入通道数为 6, 输出通道数为 16, 卷积核大小为 5x5; 再然后就是输入特征数为 400, 输出特征数为 120 的全连接层; 输入特征数为 120, 输出特征数为 84 的全连接层; 输入特征数为 84, 输出特征数为 10 的全连接层

```
1 class Net(nn.Module):
2     def __init__(self):
3         super().__init__()
4         self.conv1 = nn.Conv2d(3, 6, 5) # 4, 6, 28, 28
5         self.pool = nn.MaxPool2d(2, 2)
6         self.conv2 = nn.Conv2d(6, 16, 5)
7         self.fc1 = nn.Linear(16 * 5 * 5, 120)
8         self.fc2 = nn.Linear(120, 84)
9         self.fc3 = nn.Linear(84, 10)
10
```

```

11     def forward(self, x):
12         x = self.pool(F.relu(self.conv1(x)))
13         x = self.pool(F.relu(self.conv2(x)))
14         x = torch.flatten(x, 1) # flatten all dimensions except batch
15         x = F.relu(self.fc1(x))
16         x = F.relu(self.fc2(x))
17         x = self.fc3(x)
18         return x

```

搭建成功模型后我们可以把它输出出来:

```

Net(
  (conv1): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))
  (pool): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
  (fc1): Linear(in_features=400, out_features=120, bias=True)
  (fc2): Linear(in_features=120, out_features=84, bias=True)
  (fc3): Linear(in_features=84, out_features=10, bias=True)
)

```

图 2: 原始 CNN 网络结构图

由此可见该网络的结构还是非常简单的

(三) 原始 CNN 的训练与评估

搭建完基本的 MLP 后我们就可以开始对其展开训练与评估, 实验要求我们采用 CIFAR10 数据集, 在进行训练之前我们需要对其进行预处理, 代码如下:

```

1 transform = transforms.Compose([
2     transforms.RandomCrop(32, padding=4),
3     transforms.RandomHorizontalFlip(),
4     transforms.ToTensor(),
5     transforms.Normalize((0.4914, 0.4822, 0.4465), (0.2023, 0.1994,
6         0.2010)),
7 ])
8 trainset = torchvision.datasets.CIFAR10(root='./data', train=True, download=
9     True, transform=transform)
10 trainloader = torch.utils.data.DataLoader(trainset, batch_size=128, shuffle=
11     True, num_workers=2)
12
13 testset = torchvision.datasets.CIFAR10(root='./data', train=False, download=
14     True, transform=transform)
15 testloader = torch.utils.data.DataLoader(testset, batch_size=100, shuffle=
16     False, num_workers=2)

```

训练函数也很简单, 具体如下:

```

1 def train(model, criterion, optimizer, trainloader, valloader, epochs):
2     train_loss_history = []
3     val_loss_history = []

```

```
4     val_accuracy_history = []
5
6     for epoch in range(epochs):
7         model.train()
8         running_loss = 0.0
9         for i, data in enumerate(trainloader, 0):
10             inputs, labels = data
11             optimizer.zero_grad()
12
13             outputs = model(inputs)
14             loss = criterion(outputs, labels)
15             loss.backward()
16             optimizer.step()
17
18             running_loss += loss.item()
19             if i % 2000 == 1999:
20                 print('[%d, %5d] training loss: %.3f' %
21                       (epoch + 1, i + 1, running_loss / 2000))
22                 running_loss = 0.0
23
24         # 计算在验证集上的loss和准确度
25         model.eval()
26         val_running_loss = 0.0
27         correct = 0
28         total = 0
29         with torch.no_grad():
30             for data in valloader:
31                 images, labels = data
32                 outputs = model(images)
33                 val_loss = criterion(outputs, labels)
34                 val_running_loss += val_loss.item()
35                 _, predicted = torch.max(outputs, 1)
36                 total += labels.size(0)
37                 correct += (predicted == labels).sum().item()
38
39         train_loss_history.append(running_loss / len(trainloader))
40         val_loss_history.append(val_running_loss / len(valloader))
41         val_accuracy_history.append(100 * correct / total)
42
43         print('Epoch %d: Validation accuracy %d %%' % (epoch + 1, 100 *
44               correct / total))
45     PATH = './cifar_10_net.pth'
46     torch.save(net.state_dict(), PATH)
47
48     return train_loss_history, val_loss_history, val_accuracy_history
```

实现该网络的训练和评估后我们得到下面的结果:




图 3: 模型评估结果

我们可以看到原始网络结构的准确率相对较低, 只有 0.62. 下面我们讲尝试着改进网络结构提升模型的准确率

(四) ResNet 的实现

1. ResNet18 模型

在原始的 ResNet 论文中向我们提供了两类模型, 一种是适用于低层数的网络, 一种是适用高层数的网络. 它们的思想大致相同, 都是在原始的网络结构中增加残差结构, 但是具体的不同:

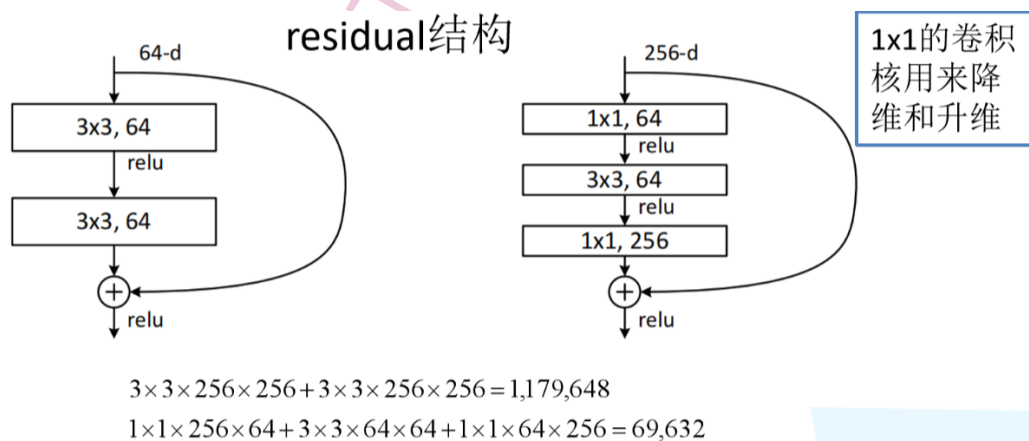


图 4: ResNet 的两种残差结构

在本次实验中我们采用了类似 ResNet18 的模型 (具体的卷积参数与原始不同), 显然我们应该选用左侧的残差结构, 具体实现代码如下:

```
1 # 定义 ResNet 基本块
2 class BasicBlock(nn.Module):
```

```

3     expansion = 1
4
5     def __init__(self, in_planes, planes, stride=1):
6         super(BasicBlock, self).__init__()
7         self.conv1 = nn.Conv2d(in_planes, planes, kernel_size=3, stride=
            stride, padding=1, bias=False)
8         self.bn1 = nn.BatchNorm2d(planes)
9         self.relu = nn.ReLU(inplace=True)
10        self.conv2 = nn.Conv2d(planes, planes, kernel_size=3, stride=1,
            padding=1, bias=False)
11        self.bn2 = nn.BatchNorm2d(planes)
12        self.shortcut = nn.Sequential()
13        if stride != 1 or in_planes != self.expansion * planes:
14            self.shortcut = nn.Sequential(
15                nn.Conv2d(in_planes, self.expansion * planes, kernel_size=1,
                    stride=stride, bias=False),
16                nn.BatchNorm2d(self.expansion * planes)
17            )
18        def forward(self, x):
19            out = self.relu(self.bn1(self.conv1(x)))
20            out = self.bn2(self.conv2(out))
21            out += self.shortcut(x)
22            out = self.relu(out)
23            return out

```

上面我们定义了 ResNet 网络结构的基本块,最引人瞩目的是引入了残差连接结构 shortcut, 其将前一层的输入直接加到后一层的输出上,这样可以保留前一层的信息并传递到后一层,从而更好地训练深层网络。实现完这些后我们就可以实现 Resnet 网络的搭建,具体实现代码如下:

```

1     class ResNet(nn.Module):
2     def __init__(self, block, num_blocks, num_classes=10):
3         super(ResNet, self).__init__()
4         self.in_planes = 64
5
6         self.conv1 = nn.Conv2d(3, 64, kernel_size=3, stride=1, padding=1,
            bias=False)
7         self.bn1 = nn.BatchNorm2d(64)
8         self.relu = nn.ReLU(inplace=True)
9         self.layer1 = self._make_layer(block, 64, num_blocks[0], stride=1)
10        self.layer2 = self._make_layer(block, 128, num_blocks[1], stride=2)
11        self.layer3 = self._make_layer(block, 256, num_blocks[2], stride=2)
12        self.layer4 = self._make_layer(block, 512, num_blocks[3], stride=2)
13        self.avgpool = nn.AdaptiveAvgPool2d((1, 1))
14        self.fc = nn.Linear(512 * block.expansion, num_classes)
15
16        def _make_layer(self, block, planes, num_blocks, stride):
17            strides = [stride] + [1] * (num_blocks - 1)
18            layers = []

```

```

19         for stride in strides:
20             layers.append(block(self.in_planes, planes, stride))
21             self.in_planes = planes * block.expansion
22         return nn.Sequential(*layers)
23
24     def forward(self, x):
25         x = self.relu(self.bn1(self.conv1(x)))
26         x = self.layer1(x)
27         x = self.layer2(x)
28         x = self.layer3(x)
29         x = self.layer4(x)
30         x = self.avgpool(x)
31         x = x.view(x.size(0), -1)
32         x = self.fc(x)
33         return x
34
35 def ResNet18():
36     return ResNet(BasicBlock, [2, 2, 2, 2])

```

实现这些后我们就可以对实验结果进行评估, 首先我们需要打印其网络结构

```

ResNet(
  (conv1): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
  (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
  (relu): ReLU(inplace=True)
  (layer1): Sequential(
    (0): BasicBlock(
      (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
      (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (relu): ReLU(inplace=True)
      (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
      (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (shortcut): Sequential()
    )
    (1): BasicBlock(
      (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
      (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (relu): ReLU(inplace=True)
      (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False)
      (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
      (shortcut): Sequential()
    )
  )
  (layer2): Sequential(
    (0): BasicBlock(
      (conv1): Conv2d(64, 128, kernel_size=(3, 3), stride=(2, 2), padding=(1, 1), bias=False)
    )
    ...
  )
  (avgpool): AdaptiveAvgPool2d(output_size=(1, 1))
  (fc): Linear(in_features=512, out_features=10, bias=True)

```

图 5: ResNet 的网络结构

然后我们观察其训练评估结果



图 6: ResNet 的评估结果

2. 带 SE 结构的 ResNet

接下来我们尝试在 ResNet 的结构上加上 SEblock, 具体实现代码如下:

```

1  # 定义 SE 模块
2  class SEModule(nn.Module):
3      def __init__(self, in_channels, reduction=16):
4          super(SEModule, self).__init__()
5          self.avg_pool = nn.AdaptiveAvgPool2d(1)
6          self.fc = nn.Sequential(
7              nn.Linear(in_channels, in_channels // reduction, bias=False),
8              nn.ReLU(inplace=True),
9              nn.Linear(in_channels // reduction, in_channels, bias=False),
10             nn.Sigmoid()
11         )
12
13     def forward(self, x):
14         b, c, _, _ = x.size()
15         y = self.avg_pool(x).view(b, c)
16         y = self.fc(y).view(b, c, 1, 1)
17         return x * y.expand_as(x)
18
19 # 定义 ResNet 基本块 (带 SE 结构)
20 class SEBasicBlock(nn.Module):
21     expansion = 1
22
23     def __init__(self, in_planes, planes, stride=1, reduction=16):
24         super(SEBasicBlock, self).__init__()
25         self.conv1 = nn.Conv2d(in_planes, planes, kernel_size=3, stride=
26             stride, padding=1, bias=False)
27         self.bn1 = nn.BatchNorm2d(planes)

```

```

27     self.relu = nn.ReLU(inplace=True)
28     self.conv2 = nn.Conv2d(planes, planes, kernel_size=3, stride=1,
29                             padding=1, bias=False)
30     self.bn2 = nn.BatchNorm2d(planes)
31     self.se = SEModule(planes, reduction)
32
33     self.shortcut = nn.Sequential()
34     if stride != 1 or in_planes != self.expansion * planes:
35         self.shortcut = nn.Sequential(
36             nn.Conv2d(in_planes, self.expansion * planes, kernel_size=1,
37                       stride=stride, bias=False),
38             nn.BatchNorm2d(self.expansion * planes)
39         )
40
41     def forward(self, x):
42         out = self.relu(self.bn1(self.conv1(x)))
43         out = self.bn2(self.conv2(out))
44         out = self.se(out)
45         out += self.shortcut(x)
46         out = self.relu(out)
47         return out

```

然后 ResNet 的其他结构与初始 ResNet 相同, 完成这些后我们就可以实现模型的评估, 评估结果如下:




图 7: 带 SE 结构的 Resnet 评估结果

我们观察到相较于原始 ResNet, 改进之后的准确率并没有显著提升, 而且有些许下降。起初我们认为是 reduction 参数的问题, 但是尝试多个参数后准确率还是没有提升。推测可能是因为 CIFAR10 数据集较小, ResNet 已经可以很好地反映数据特征, 在这基础上增加参数反而会导致过拟合情况的出现。要想增加训练的准确度我们可以从实时调整学习率参数入手。

(五) DenseNet 的实现

DenseNet（密集连接网络）是一种高效的卷积神经网络结构，旨在最大化特征的重用并解决深层网络中的梯度消失问题。DenseNet 通过在每一层之间建立密集连接，使得特征图能够更直接地传递和重用。其中 DenseNet 由多个 DenseBlock(密集块) 以及 TransitionLayer(过渡层) 组成，每一层都接收前面所有层的输出作为其输入。

$$\mathbf{x}_l = H_l([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{l-1}])$$

其中 \mathbf{x}_l 是第 l 层的输出， $[\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{l-1}]$ 表示将所有之前层的输出拼接起来， H_l 是第 l 层的非线性转换（通常是卷积、批归一化和 ReLU 的组合）。下面我们尝试着构建我们的 DenseNet:

```

1 class BottleneckLayer(nn.Module):
2     def __init__(self, in_channels, growth_rate):
3         super(BottleneckLayer, self).__init__()
4         self.bn1 = nn.BatchNorm2d(in_channels)
5         self.conv1 = nn.Conv2d(in_channels, 4 * growth_rate, kernel_size=1,
6                                 bias=False)
7         self.bn2 = nn.BatchNorm2d(4 * growth_rate)
8         self.conv2 = nn.Conv2d(4 * growth_rate, growth_rate, kernel_size=3,
9                                 padding=1, bias=False)
10
11     def forward(self, x):
12         out = self.conv1(F.relu(self.bn1(x)))
13         out = self.conv2(F.relu(self.bn2(out)))
14         out = torch.cat([x, out], 1)
15         return out
16
17 class TransitionLayer(nn.Module):
18     def __init__(self, in_channels, out_channels):
19         super(TransitionLayer, self).__init__()
20         self.bn = nn.BatchNorm2d(in_channels)
21         self.conv = nn.Conv2d(in_channels, out_channels, kernel_size=1, bias=
22                                 False)
23
24     def forward(self, x):
25         out = self.conv(F.relu(self.bn(x)))
26         out = F.avg_pool2d(out, 2)
27         return out
28
29 class DenseBlock(nn.Module):
30     def __init__(self, num_layers, in_channels, growth_rate):
31         super(DenseBlock, self).__init__()
32         layers = []
33         for i in range(num_layers):
34             layers.append(BottleneckLayer(in_channels + i * growth_rate,
35                                           growth_rate))
36         self.block = nn.Sequential(*layers)
37
38     def forward(self, x):

```

```
35         return self.block(x)
36
37 class DenseNet(nn.Module):
38     def __init__(self, num_classes=10, growth_rate=12, block_config=(16, 16,
39         16)):
40         super(DenseNet, self).__init__()
41         self.conv1 = nn.Conv2d(3, 2 * growth_rate, kernel_size=3, padding=1,
42             bias=False)
43         self.dense1 = DenseBlock(block_config[0], 2 * growth_rate,
44             growth_rate)
45         self.trans1 = TransitionLayer(2 * growth_rate + block_config[0] *
46             growth_rate, growth_rate)
47         self.dense2 = DenseBlock(block_config[1], growth_rate, growth_rate)
48         self.trans2 = TransitionLayer(growth_rate + block_config[1] *
49             growth_rate, growth_rate)
50         self.dense3 = DenseBlock(block_config[2], growth_rate, growth_rate)
51         self.bn = nn.BatchNorm2d(growth_rate + block_config[2] * growth_rate)
52         self.linear = nn.Linear(growth_rate + block_config[2] * growth_rate,
53             num_classes)
54
55     def forward(self, out):
56         out = self.conv1(out)
57         out = self.dense1(out)
58         out = self.trans1(out)
59         out = self.dense2(out)
60         out = self.trans2(out)
61         out = self.dense3(out)
62         out = torch.squeeze(F.avg_pool2d(F.relu(self.bn(out)), 8))
63         out = F.log_softmax(self.linear(out), dim=1)
64         return out
```

在实验中为了保证运行速度, 同时兼顾准确率我们选取了 growthrate=32, blockconfig=(8, 8, 8) 接下来我们观察其结果:

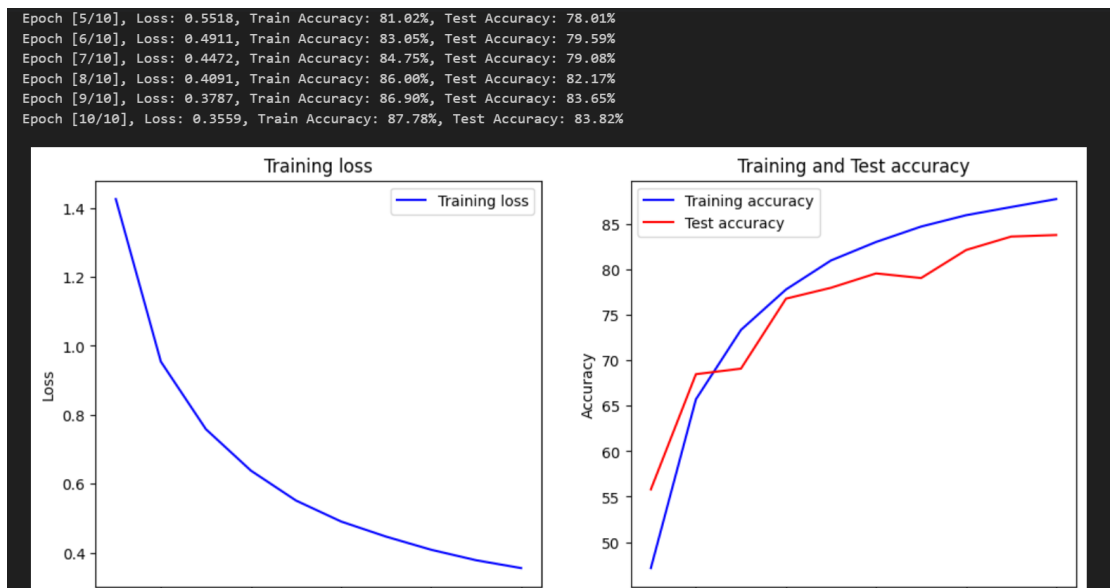


图 8: Densenet 的评估结果

我们观察到 Densenet 的准确率相对来说也是比较高的,当然我们也可以尝试其他的参数来对该模型进行优化,限于时间这里不再展开。

四、 总结

本次实验成功实现卷积神经网络模型,并成功实现了 ResNet 以及带 SE 结构的 ResNet,以及 DenseNet. 通过这次实验我们对卷积神经网络的结构有了更加深刻的理解.